

Sinais Forenses Interpretáveis para Detecção de Vídeos Gerados por Inteligência Artificial sob Mudança de Gerador

Estrutura inicial do manuscrito e plano de trabalho

Nome do(a) orientador(a)
email@instituicao.br

Nome dos(as) discentes
Instituição

Versão de trabalho — setembro de 2026

Resumo

Os avanços recentes em modelos de geração de vídeo tornaram a distinção entre conteúdo real e sintético progressivamente mais difícil, especialmente quando o detector é avaliado em geradores não observados durante o treinamento. Este trabalho investiga uma representação forense explícita e auditável, composta por sinais de textura, bordas, estrutura local, resíduo, frequência, fotometria e comportamento temporal, extraídos de regiões como rosto, olhos, boca, corpo e fundo. A hipótese central é que a combinação de pistas de baixo nível pode capturar inconsistências compartilhadas por diferentes geradores, desde que a avaliação controle atalhos relacionados a conteúdo, identidade, movimento, taxa de quadros, resolução e compressão. O estudo será conduzido principalmente no benchmark DF26, usando partições agrupadas por conteúdo e um protocolo de gerador não visto. **[Inserir aqui, somente após os experimentos, os resultados principais com métricas e intervalos de confiança.]**

Palavras-chave: vídeo sintético; detecção de conteúdo gerado por IA; forense multimídia; sinais interpretáveis; generalização; mudança de domínio.

Nota de integridade científica: não inserir métricas, resultados, comparações ou conclusões que ainda não tenham sido obtidos por uma execução versionada e auditável do experimento.

1 Introdução

Modelos contemporâneos de texto-para-vídeo e imagem-para-vídeo produzem cenas com alto grau de realismo visual e temporal. Esse avanço reduz a utilidade de detectores desenvolvidos apenas para manipulações faciais tradicionais, como troca de rosto e reenactment. O problema torna-se particularmente relevante em vídeos de pronunciamentos, entrevistas e comunicação pública, nos quais a autenticidade do conteúdo pode influenciar decisões sociais e políticas.

Um obstáculo central é a generalização. Um detector pode apresentar desempenho elevado quando os dados de treino e teste compartilham geradores, fontes, codecs ou padrões de movimento, mas falhar diante de um novo processo generativo. O benchmark DF26 evidencia essa dificuldade ao reunir vídeos de fala produzidos por geradores recentes e ao reportar desempenho próximo ao acaso para seres humanos e diferentes detectores existentes [1]. Estudos recentes também mostram que parte do desempenho de detectores temporais pode decorrer de vieses de amostragem, movimento, resolução ou pré-processamento, e não necessariamente de propriedades intrínsecas da geração sintética [2].

Este trabalho parte de uma direção complementar aos modelos profundos de ponta a ponta. Em vez de aprender toda a representação diretamente dos pixels, o pipeline calcula descritores determinísticos e semanticamente nomeados. Esses descritores são agregados por vídeo e fornecidos

a classificadores tabulares. Essa separação permite analisar quais famílias de sinais e quais regiões contribuem para a decisão, além de facilitar testes de robustez e a identificação de atalhos.

A pergunta central do artigo é: *até que ponto sinais forenses explícitos, regionais e temporais discriminam vídeos reais e sintéticos quando o gerador de teste não aparece no treinamento e os principais fatores de confusão são controlados?*

As contribuições pretendidas são:

1. uma representação tabular forense organizada por família de sinal, região semântica e comportamento temporal;
2. um protocolo de avaliação que combine mudança de gerador e separação de conteúdo relacionado;
3. uma análise de ablação por família, região e temporalidade;
4. uma auditoria de atalhos associados a metadados, movimento, amostragem, resolução, codec e compressão.

A fazer pela equipe: Reescrever o último parágrafo das contribuições após os experimentos. Cada contribuição declarada deverá apontar para uma tabela, figura, artefato de código ou resultado verificável.

2 Fundamentação teórica

2.1 Detecção de vídeos totalmente gerados

A literatura de deepfakes foi inicialmente dominada por manipulações locais do rosto. Vídeos totalmente gerados constituem um regime diferente: aparência, fundo, iluminação e movimento podem ser sintetizados conjuntamente. Por isso, artefatos de recorte ou mistura de face, comuns em bases anteriores, não são necessariamente informativos nesse novo cenário.

Abordagens recentes utilizam redes espaço-temporais, representações aprendidas, modelos de estado e detectores baseados em frequência. O DeMamba, por exemplo, explora inconsistências espaciais e temporais em um benchmark de grande escala [4]. O UNITE procura cobrir tanto manipulações parciais quanto vídeos totalmente sintéticos [5]. Já estratégias de orientação forense procuram conduzir o modelo a pistas de baixo nível que sejam compartilhadas por arquiteturas generativas distintas [3].

Esses resultados não eliminam o problema de mudança de domínio. Geradores novos, recompressão de plataformas e diferenças entre as fontes reais e sintéticas podem alterar as distribuições observadas. Consequentemente, o desempenho dentro de uma mesma base não é evidência suficiente de uma propriedade universal dos vídeos gerados.

A fazer pela equipe: Construir uma tabela de trabalhos relacionados contendo: método, representação, datasets, tipo de split, geradores não vistos, controles de compressão/movimento, métricas, disponibilidade de código e limitações. Consultar os artigos completos, não apenas resumos ou páginas secundárias.

2.2 Forense interpretável e sinais de baixo nível

Uma representação interpretável não significa que cada atributo possua poder causal ou seja isoladamente suficiente para detectar conteúdo sintético. Significa que a grandeza calculada tem definição conhecida, unidade de análise explícita e limites de interpretação documentados. Neste projeto, os sinais são organizados em cinco grupos.

2.2.1 Grupo A: textura, bordas e nitidez

O Local Binary Pattern (LBP) descreve a relação entre um pixel e sua vizinhança e é uma referência clássica para caracterização de textura [6]. Para uma vizinhança de P pontos e raio R , uma forma geral do código é

$$\text{LBP}_{P,R} = \sum_{p=0}^{P-1} s(g_p - g_c) 2^p, \quad s(x) = \begin{cases} 1, & x \geq 0, \\ 0, & x < 0. \end{cases} \quad (1)$$

O pipeline utiliza escalas distintas e resume propriedades das distribuições dos códigos, como entropia normalizada, uniformidade e ocupação dos bins. Como os códigos LBP são categorias, momentos numéricos arbitrários dos próprios códigos não devem receber interpretação física.

Gradientes de Sobel representam intensidade e orientação de transições locais. O Laplaciano responde à segunda derivada espacial e fornece indicadores de bordas finas e nitidez. Essas grandezas também são sensíveis a blur, sharpening, resize e compressão; portanto, diferenças entre classes precisam ser reavaliadas sob perturbações controladas.

2.2.2 Grupo B: estrutura local

O SIFT detecta pontos de interesse e descreve padrões locais com relativa robustez a escala e rotação [7]. O projeto resume quantidade, densidade, cobertura espacial, resposta, escala, orientação e autossimilaridade dos descritores em cada região. Esses valores podem refletir estrutura local, mas também conteúdo, pose, dimensão da região e qualidade de imagem.

A similaridade entre patches complementa o SIFT ao medir repetição de padrões locais. A amostragem deve ser determinística e espacialmente distribuída, e as contagens de patches válidos devem ser tratadas como controle de qualidade.

2.2.3 Grupo C: resíduo de alta passagem

O resíduo bilateral é definido por

$$R = I - \text{Bilateral}(I), \quad (2)$$

em que o filtro bilateral suaviza variações preservando parte das bordas [8]. Estatísticas de R descrevem magnitude, dispersão, caudas, autocorrelação espacial e correlação entre canais.

Esse resíduo contém uma mistura de textura, bordas, ruído, sharpening e compressão. Ele deve ser apresentado como um *baseline* de alta passagem, e não como estimativa de PRNU, Noiseprint ou ruído de sensor.

2.2.4 Grupo D: frequência espacial

Para uma região em tons de cinza, o pipeline centraliza o sinal, aplica uma janela de Hann e calcula a transformada discreta de Fourier:

$$\tilde{I}(x, y) = (I(x, y) - \bar{I})w(x, y), \quad F(u, v) = \mathcal{F}_2\{\tilde{I}\}, \quad P(u, v) = |F(u, v)|^2. \quad (3)$$

Razões de potência por banda, centroide radial, entropia, planicidade, anisotropia e inclinação espectral resumem a distribuição de energia. Pistas frequenciais podem revelar artefatos de arquiteturas generativas, mas também são fortemente afetadas por codec, taxa de compressão e interpolação. Trabalhos recentes mostram tanto o potencial das pistas de frequência quanto a necessidade de testá-las após recompressão [3, 2].

2.2.5 Grupo E: fotometria regional

As métricas fotométricas resumem luminância, cromaticidade, saturação, iluminação suavizada, gradientes e proporções de pixels escuros, claros ou clipados. Assimetrias horizontais e verticais permitem descrever desequilíbrios entre partes de uma região.

O módulo de candidatos de sombra usa uma aproximação inspirada em Retinex para identificar pixels abaixo de uma estimativa local de iluminação. Esses valores são *proxies* fotométricos: não estimam completamente fonte de luz, normais, reflectância ou geometria tridimensional. Materiais escuros e exposição local podem gerar respostas semelhantes.

2.3 Regiões semânticas e contrastes regionais

Os descritores são extraídos de rosto completo, olhos, boca, corpo e fundo. A hipótese é que uma inconsistência possa ser localizada ou aparecer como contraste entre regiões. Entretanto, regiões incorretas, faces pequenas, oclusões e fallbacks geométricos podem produzir separação artificial.

Cada observação deve preservar vídeo, frame, tempo, identidade rastreada, região, origem da detecção e indicadores de qualidade. O MediaPipe fornece a base operacional para detecção e segmentação [9], mas a validade científica das regiões depende de auditoria visual e quantitativa.

2.4 Temporalidade

Se $x(t)$ representa um sinal regional amostrado no tempo físico, as primeiras e segundas diferenças podem ser aproximadas por

$$\Delta x_i = \frac{x(t_{i+1}) - x(t_i)}{t_{i+1} - t_i}, \quad \Delta^2 x_i = \frac{\Delta x_{i+1} - \Delta x_i}{\tilde{t}_{i+1} - \tilde{t}_i}. \quad (4)$$

O pipeline também calcula dispersão robusta, autocorrelação e estatísticas de frequência temporal. Usar timestamps é fundamental porque índices de frames podem representar intervalos físicos diferentes. Ainda assim, menor ou maior variação temporal pode ser apenas consequência de movimento, duração ou FPS. Por isso, a contribuição temporal deverá ser avaliada antes e depois do balanceamento desses fatores.

2.5 Generalização, atalhos e vazamento experimental

Atalhos são variáveis que permitem prever o rótulo dentro de uma base sem representar a propriedade científica de interesse. Exemplos incluem resolução, codec, FPS, duração, origem, quantidade de movimento, padding e política de amostragem. Detectores temporais recentes mostraram quedas substanciais quando vieses de movimento e pré-processamento foram controlados [2].

Outro risco é o vazamento de conteúdo. Se versões reais e sintéticas derivadas do mesmo clipe, prompt ou identidade aparecem em treino e teste, o modelo pode reconhecer o conteúdo em vez do processo de geração. Por isso, o artigo propõe separar simultaneamente famílias de geradores e grupos de conteúdo.

2.6 Classificadores tabulares e interpretação

Após a extração, cada vídeo é representado por um vetor z_V , e um classificador estima

$$\hat{y} = g_\theta(z_V). \quad (5)$$

Regressão logística regularizada, Random Forest e gradient boosting representam baselines com diferentes relações entre complexidade e interpretação [10, 11]. Imputação, normalização, seleção de atributos e calibração devem ser ajustadas exclusivamente nos dados de treino de cada

fold. Coeficientes padronizados e importância por permutação agrupada podem apoiar a análise, mas não demonstram causalidade.

3 Perguntas de pesquisa e hipóteses

RQ1

Sinais forenses explícitos discriminam vídeos reais e sintéticos quando o gerador de teste não aparece no treinamento?

RQ2

Quais famílias de sinais permanecem estáveis entre geradores?

RQ3

Quais regiões oferecem evidência complementar e quais capturam predominantemente conteúdo ou erro de segmentação?

RQ4

Os derivados temporais acrescentam informação após controlar FPS, duração e movimento?

RQ5

O desempenho persiste sob compressão, resize, mudanças de FPS e separação de conteúdo relacionado?

As hipóteses iniciais são:

- H1. A representação forense supera um baseline baseado apenas em metadados nos testes com gerador não visto.
- H2. Sinais espectrais e residuais apresentam maior transferência entre geradores, mas são sensíveis a recompressão e resize.
- H3. A temporalidade oferece ganho incremental apenas quando amostragem e movimento são controlados.
- H4. Contrastes regionais acrescentam informação sem depender predominantemente de fallback ou falha do detector de regiões.

A fazer pela equipe: Congelar perguntas e hipóteses antes da análise confirmatória. Se uma hipótese for refutada, manter e relatar a refutação; não reescrever a hipótese para coincidir com os resultados.

4 Materiais e métodos

4.1 Estado atual do repositório

O repositório implementa ingestão, pré-processamento regional, extração dos grupos A–E, agregações temporais, camadas Bronze/Silver/Gold, contratos de dados e versionamento por DVC. No momento de preparação desta estrutura, não estavam disponíveis localmente a base DF26 processada, a Gold experimental, um módulo completo de treinamento em `src/ml` ou resultados persistidos. Os notebooks também não continham saídas executadas.

Portanto, as seções de resultados e conclusão deste documento são apenas uma estrutura de preenchimento. O artefato registrado no `dvc.lock` corresponde a validação operacional e não deve ser tratado como amostra científica.

4.2 Dados

O DF26 será a base principal. O benchmark contém 271 vídeos reais e 2.420 vídeos sintéticos de sete famílias de geradores em cenários de fala com uma pessoa [1]. A licença e os papéis experimentais definidos pela base devem ser respeitados, mantendo geradores comerciais apenas para avaliação final.

O catálogo adicional do projeto contém 2.039 links, dos quais 1.072 estão rotulados como reais e 967 como falsos. Essa coleção somente poderá ser usada como validação externa após auditoria de disponibilidade, licença, proveniência, rótulos, duplicatas e vídeos derivados.

A fazer pela equipe: Produzir a tabela final de composição da amostra após todos os filtros, com contagens por classe, gerador, cenário, modo de geração, resolução, FPS, codec e motivo de exclusão.

4.3 Pré-processamento e regiões

Os vídeos são amostrados em tempo físico. O pipeline atual prevê 5 fps e até 25 frames no DF26, preservando FPS, duração, contagem de frames e resolução originais para auditoria. MediaPipe é usado para produzir regiões de rosto, olhos, boca, corpo e fundo, com registro de confiança, origem da região e fallback.

A fazer pela equipe: Validar a política de amostragem, auditar visualmente uma amostra estratificada e definir critérios objetivos para face pequena, oclusão, pose, blur, troca de identidade e fallback.

4.4 Extração e agregação dos sinais

Para o vídeo V , frame t , região r e descritor k , define-se

$$x_{V,t,r,k} = \phi_k(I_{V,t}, r). \quad (6)$$

As observações são agregadas por vídeo, região e track, gerando estatísticas estáticas e temporais:

$$z_V = \Psi(\Phi(I_1), \Phi(I_2), \dots, \Phi(I_T)). \quad (7)$$

Colunas de governança, caminhos, nomes de arquivo, fonte e identidade do gerador não podem entrar como atributos preditivos. Variáveis de aquisição serão reservadas para auditoria e para um baseline de atalhos.

4.5 Protocolo de avaliação

O protocolo LOGOS atualmente implementado precisa ser corrigido: os folds existentes colocam todos os vídeos reais em treino e somente falsos do gerador omitido em teste. Isso não permite calcular uma métrica binária real-versus-falso válida no conjunto de teste.

O protocolo proposto terá dois eixos:

1. **mudança de gerador:** uma família open-weight é omitida do treinamento;
2. **mudança de conteúdo:** df26_clip_id e demais chaves de identidade/conteúdo são divididas em grupos disjuntos.

Cada teste deverá conter vídeos reais e falsos. Treino, validação e teste não podem compartilhar clipes relacionados. O conjunto comercial será aberto uma única vez, depois que representação, modelos, hiperparâmetros e limiares forem congelados.

A fazer pela equipe: Implementar o novo gerador de splits, adicionar testes automatizados de ausência de sobreposição e salvar a tabela de grupos usada em cada repetição.

4.6 Baselines e ablações

Os experimentos mínimos serão:

Tabela 1: Experimentos mínimos planejados.

Experimento	Finalidade
Aleatório e majoritário	Referências inferiores de desempenho.
Metadados somente	Quantificar atalhos de aquisição.
Regressão logística	Baseline linear regularizado.
Random Forest/boosting	Baselines tabulares não lineares.
Grupos A–E isolados	Medir contribuição de cada família.
Estático vs. temporal	Medir ganho temporal incremental.
Regiões isoladas	Localizar a fonte da evidência.
Sem fallback	Testar dependência de falhas regionais.
Perturbações	Medir robustez a compressão, resize, FPS, blur e ruído.
Holdout comercial	Avaliação final com pipeline congelado.

4.7 Métricas e análise estatística

Serão reportadas AUROC, macro-AUROC entre geradores, balanced accuracy, AUPRC com prevalência, TPR em FPR fixo, Brier score e erro esperado de calibração. Também serão medidos tempo de extração, memória e dimensionalidade.

Intervalos de confiança serão estimados por bootstrap agrupado em `df26_clip_id`. Comparações de modelos usarão as mesmas unidades de teste. Análises univariadas deverão corrigir múltiplas comparações. O vídeo é a unidade mínima de avaliação; frames do mesmo vídeo não serão tratados como amostras independentes.

A fazer pela equipe: Definir previamente número de repetições, sementes, FPR operacional, método de correção de múltiplos testes e regra de seleção do modelo final.

5 Plano de trabalho até o artigo

5.1 Ordem recomendada

1. corrigir o protocolo antes de consultar resultados confirmatórios;
2. estabilizar o ambiente e executar os testes;
3. processar um piloto estratificado e auditar as regiões;
4. executar EDA de qualidade e corrigir problemas de medição;
5. processar a base completa e treinar os baselines;
6. executar ablações e controles de robustez;
7. congelar o pipeline e avaliar o holdout comercial;
8. preencher resultados, discussão, limitações e conclusão.

Tabela 2: Pacotes de trabalho e evidências de conclusão.

ID	Frente	Entrega verificável	Responsável
P1	Protocolo	Splits agrupados, testes de vazamento e plano estatístico congelado.	[nome]
P2	Ambiente	Dependências fixadas; testes e pipeline reproduzidos em ambiente limpo.	[nome]
P3	Dados	DF26 obtido sob licença; manifestos, hashes e exclusões registrados.	[nome]
P4	Regiões	Auditoria visual estratificada e relatório de cobertura/fallback.	[nome]
P5	EDA	Relatório de qualidade, confundidores, correlação e estabilidade.	[nome]
P6	Modelagem	Baselines, seleção interna aos folds e calibração implementados.	[nome]
P7	Ablações	Resultados por família, região, temporalidade e gerador.	[nome]
P8	Robustez	Compressão, resize, FPS, movimento e controles negativos.	[nome]
P9	Comparação	Pelo menos um método externo sob protocolo compatível.	[nome]
P10	Redação	Figuras, tabelas, discussão, limitações e pacote reproduzível.	[nome]

5.2 Critérios mínimos para submissão

O manuscrito somente deverá ser submetido quando:

- cada conjunto de teste contiver ambas as classes;
- não houver sobreposição indevida de conteúdo, identidade ou derivados;
- a cobertura e as falhas das regiões estiverem documentadas;
- os experimentos forem reproduzíveis em ambiente limpo;
- o ganho sobre baselines simples e metadados persistir em geradores não vistos, ou a ausência desse ganho estiver rigorosamente demonstrada;
- os principais confundidores tiverem sido controlados;
- o holdout comercial tiver sido usado apenas depois do congelamento;
- médias vierem acompanhadas de resultados por gerador e intervalos de confiança.

6 Resultados

Nota de integridade científica: não inserir métricas, resultados, comparações ou conclusões que ainda não tenham sido obtidos por uma execução versionada e auditável do experimento.

6.1 Qualidade dos dados e das regiões

A fazer pela equipe: Inserir contagens, exclusões, cobertura regional, confiança, fallback, tracks e falhas. Apresentar esses resultados antes das métricas preditivas.

6.2 Generalização para geradores não vistos

A fazer pela equipe: Inserir a tabela principal por fold e gerador, com intervalos de confiança. Incluir o baseline de metadados na mesma comparação.

6.3 Ablação de famílias e regiões

A fazer pela equipe: Relatar grupos A–E, regiões e contrastes. Discutir estabilidade entre geradores, e não apenas o melhor valor médio.

6.4 Contribuição da temporalidade

A fazer pela equipe: Comparar modelos estáticos e temporais antes e depois de controlar FPS, duração e movimento.

6.5 Robustez e avaliação comercial

A fazer pela equipe: Relatar degradação sob perturbações e, por último, o holdout comercial. Registrar qualquer análise realizada após a abertura desse holdout.

7 Discussão

A discussão deverá responder, com base nos resultados:

- quais sinais permanecem úteis entre geradores;
- quais diferenças desaparecem quando confundidores são controlados;
- se regiões semânticas oferecem evidência complementar;
- se a temporalidade mede artefato generativo ou viés de movimento;
- qual é a relação entre desempenho, custo e auditabilidade;
- quais conclusões não podem ser generalizadas além do DF26.

Um resultado próximo ao acaso após controles não invalida automaticamente o trabalho. Ele pode sustentar uma contribuição de auditoria ou resultado negativo, desde que o protocolo seja sólido e a causa da queda seja analisada.

A fazer pela equipe: Confrontar cada hipótese com os resultados e com trabalhos primários. Separar evidência observada, interpretação plausível e especulação.

8 Limitações, ética e reprodutibilidade

O DF26 é concentrado em vídeos curtos de uma pessoa falando, o que limita a validade externa. O desempenho pode mudar em cenas longas, múltiplas pessoas, câmeras móveis ou outros gêneros audiovisuais. Regiões incorretas, rótulos imprecisos e versões futuras dos geradores constituem ameaças adicionais.

Detectores de conteúdo sintético têm implicações de uso dual. Uma previsão não deve ser comunicada como prova definitiva de falsidade, especialmente em contextos de alto impacto. O artigo deverá descrever incerteza, limitações e condições de falha.

Para reprodutibilidade, serão publicados, dentro das restrições de licença, código, parâmetros, versões, seeds, splits, hashes, critérios de exclusão e resultados agregados. Os vídeos do DF26 não deverão ser redistribuídos fora dos termos autorizados.

9 Conclusão

Este manuscrito propõe avaliar sinais forenses explícitos para detecção de vídeos gerados por IA sob mudança de gerador e separação de conteúdo. A estrutura atual do repositório permite conduzir essa investigação, mas ainda é necessário corrigir o protocolo, processar a base experimental, auditar as regiões, implementar a modelagem e executar ablações e testes de robustez.

[Substituir este parágrafo após os experimentos por uma resposta direta às perguntas de pesquisa, delimitada aos dados e controles efetivamente avaliados.]

A Checklist da equipe antes de remover os marcadores

- ☐ Todas as referências foram conferidas nas fontes primárias.
- ☐ Toda afirmação quantitativa aponta para um artefato versionado.
- ☐ Nenhuma coluna de governança entrou como feature.
- ☐ Imputação, escala e seleção foram ajustadas dentro dos folds.
- ☐ O teste contém reais e falsos sem vazamento de conteúdo.
- ☐ Há resultados por gerador e intervalos de confiança.
- ☐ O baseline de metadados foi executado.
- ☐ As falhas de região e fallback foram auditadas.
- ☐ O holdout comercial foi aberto somente após o congelamento.
- ☐ Todas as ocorrências de “A fazer” foram resolvidas.
- ☐ O texto foi migrado para o template do evento ou periódico.

Referências

- [1] S. Shykula, A. Yermakov, I. Samarskyi, D. Mishkin, J. Cech e A. Mishchuk. DF26: We Cannot Tell Fake From Real Anymore. *arXiv preprint arXiv:2609.07369*, 2026.
- [2] J. Michels, L. Jorissen e N. Michiels. Dataset Biases and Shortcut Learning in Motion-Based AI-Generated Video Detection. *arXiv preprint arXiv:2607.00948*, 2026.
- [3] R. Corvi, D. Cozzolino, E. Prashnani, S. De Mello, K. Nagano e L. Verdoliva. Seeing What Matters: Generalizable AI-generated Video Detection with Forensic-Oriented Augmentation. *arXiv preprint arXiv:2506.16802*, 2025.
- [4] H. Chen et al. DeMamba: AI-Generated Video Detection on Million-Scale GenVideo Benchmark. *arXiv preprint arXiv:2405.19707*, 2024.
- [5] S. Kundu et al. Towards a Universal Synthetic Video Detector: From Face or Background Manipulations to Fully AI-Generated Content. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025.
- [6] T. Ojala, M. Pietikäinen e T. Mäenpää. Multiresolution Gray-Scale and Rotation Invariant Texture Classification with Local Binary Patterns. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 24(7):971–987, 2002.
- [7] D. G. Lowe. Distinctive Image Features from Scale-Invariant Keypoints. *International Journal of Computer Vision*, 60:91–110, 2004.

- [8] C. Tomasi e R. Manduchi. Bilateral Filtering for Gray and Color Images. In *Proceedings of the Sixth International Conference on Computer Vision*, pages 839–846, 1998.
- [9] C. Lugaresi et al. MediaPipe: A Framework for Building Perception Pipelines. *arXiv preprint arXiv:1906.08172*, 2019.
- [10] L. Breiman. Random Forests. *Machine Learning*, 45:5–32, 2001.
- [11] T. Chen e C. Guestrin. XGBoost: A Scalable Tree Boosting System. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.